报告正文

（一）立项依据与研究内容（建议 8000 字以下）

1. **项目的立项依据**（研究意义、国内外研究现状及发展动态分析，需结合科学研究发展趋势来论述科学意义；或结合国民经济和社会发展中迫切需要解决的关键科技问题来论述其应用前景。附主要参考文献目录）；

当前，人工智能（Artificial Intelligence，AI）与机器学习（Machine Learning，ML）正驱动着数据科学范式的深刻变革。随着深圳市“20+8”战略性新兴产业集群（特别是生物医药、大健康与人工智能产业）的纵深推进，精准医疗、公共卫生监测以及智能风控等领域积累了海量的复杂连续数据[22, 24, 32]。这些数据（如临床多维生化指标、高风险医疗支出、生物寿命特征等）普遍呈现出严格正向、极端右偏（Right-skewness）、高度过离散（Over-dispersion）以及多维强耦合的复杂非高斯特性。

尽管深度神经网络等复杂机器学习模型在特征提取方面取得了显著进展，但其在处理上述复杂非高斯数据时，仍面临基础理论层面的严峻瓶颈：一方面，传统黑盒模型往往假设数据噪声服从简单的高斯分布，导致在面对重尾或极端偏态数据时出现严重的泛化能力衰退与预测失效；另一方面，高风险的医疗健康决策对算法的可信性与可解释性提出了极高要求，而现有模型难以对数据中复杂的个体异质性（Heterogeneity）与不确定性（Uncertainty）进行精确量化。因此，构建具备严格数理基础、高度灵活且可解释的概率机器学习（Probabilistic Machine Learning）底层分布架构，已成为当前人工智能与复杂数据分析交叉领域亟待解决的关键科学问题。

针对这一痛点，本项目突破了传统统计分布[6, 9, 19]（如 Gamma、Inverse Gamma、Inverse Gaussian）均值与方差强耦合的理论局限，创新性地引入潜变量表征学习（Latent Variable Representation）思想，提出了一套面向复杂正向数据的新型广义混合伽马（Generalized Mixture Gamma）概率模型与数据驱动的稳健推断体系[12, 17]。本项目的实施，将为处理高维复杂医疗健康数据提供全新的概率生成机制与高效的优化算法（N-EM 算法[36]），为深圳市大健康与人工智能产业的可信 AI 系统部署提供核心算法底座与坚实的理论支撑。

1.1 从刚性方差约束到潜变量表征学习的演进

在处理正向偏态数据时，传统统计学与早期机器学习模型高度依赖 Gamma、逆高斯（Inverse Gaussian）及 Weibull 等经典分布族[4, 5, 37]。然而，近年来众多学者发现，这类模型在深度学习部署中存在致命的均值–方差强耦合瓶颈——其模

型结构的刚性导致无法在捕捉群体均值趋势的同时[16, 29, 31]，灵活量化因潜在异质性引发的过度离散现象。

为了打破这一局限，前沿数据科学开始引入潜变量表征思想。尽管部分工作尝试通过构建随机效应模型或引入变分自编码器（VAE）来解耦异质性噪声，但这些黑盒架构往往牺牲了参数的统计可解释性，难以满足医疗诊断等高风险场景对“可信 AI”的要求。因此，如何在保留 Gamma 分布严密可解释性的前提下，通过注入具备明确物理/统计意义的混合潜变量（如广义逆高斯族[3, 20]）来实现结构性变异与个体随机异质性的解析级方差分解，并开发能够突破复杂积分计算瓶颈的高效优化算法（如 N-EM 算法），已成为当前可解释概率机器学习领域的核心焦点。

1.2 从传统 Copula 依赖到高维正相关协同演化机制的突破

在真实世界的复杂系统中（如患者的多项肝功能生化指标 ALT/AST/ALP），多维特征之间往往存在强烈的正向协同演化机制。传统构建多元分布的统计手段主要分为两类：一是利用随机表示的方法，如 Cheriyan 和 Ramabhadran 提出的通过共享随机扰动项 Y_0 的加法构造[30]，二是基于 Copula 函数的拼接[1]。

然而，在海量高维数据的机器学习任务中，这些经典方法暴露出显著的局限：传统的加法多元构造则会导致各维度产生同质化的依赖结构（Uniform dependency）和相同的离散度，完全脱离了真实多模态数据的异构特性；而 Copula 模型在超高维下计算复杂度呈指数级增长[33]且先验选择主观随意。当前，多模态表征学习亟需一种具备底层数学支撑的联合概率架构。通过构建共享潜变量表征（Shared Latent Representation）的乘法混合机制，自然诱导多维变量间的灵活正相关性，并将其融入多元均值回归框架中以精准刻画高维协变量的联合效应，是突破多模态联合概率建模瓶颈的关键路径。

1.3 从参数化先验假设到数据驱动的非参数稳健优化的范式转移

在应对极其复杂的现实噪声时，任何预设的参数化模型（即使是高度灵活的广义逆高斯潜变量族）都不可避免地存在模型误设（Mis-specification）的风险，进而导致 AI 预测系统在分布外（Out-of-Distribution, OOD）数据上的泛化能力崩溃。为此，稳健机器学习理论正逐渐向数据驱动的非参数范式转移。

现有研究表明，通过直方图离散化或黎曼–斯蒂尔吉斯积分逼近（Riemann–Stieltjes approximation）技术，可以在无特定分布假设的前提下逼近真实的潜变量分布空间[21, 28]。但随之而来的是高维离散化带来的“维度灾难”与严重的过拟合（Over-fitting）倾向。如何将非参数离散化逼近与 Sieve 理论[13, 35]及假发现率（False Discovery Rate, FDR）自适应筛选框架深度融合，构建完全受数据驱动的非参数自适应混合模型；并结合严密的 MM（Minorization–Maximization）迭

代优化算法，在保证模型表达上限的同时压制过拟合风险，是当前提升复杂数据预测稳健性与底层算法鲁棒性的最前沿探索方向。

主要参考文献：

[1] Aas K, Czado C, Frigessi A & Bakken H (2009). Pair-copula constructions of multiple dependence. *Insurance: Mathematics and economics* **44**(2), 182–198.

[2] Akaike H (1974). A new look at the statistical model identification. *IEEE Transactions on Automatic Control* **19**(6), 716–723.

[3] Barndorff-Nielsen O & Halgreen C (1977). Infinite divisibility of the hyperbolic and generalized inverse Gaussian distributions. *Zeitschrift für Wahrscheinlichkeitstheorie und verwandte Gebiete* **38**(4), 309–311.

[4] Bownan KO & Shenton LR (1982). Properties of estimators for the gamma distribution, *Communications in Statistics—Simulation and Computation* **11**(4), 377–519.

[5] Chhikara RS & Folks JL (1988). *The Inverse Gaussian Distribution: Theory, Methodology, and Applications* (1-st Edition). CRC Press, Boca Raton.

[6] Cordeiro GM & Lemonte AJ (2012). The McDonald inverted beta distribution. *Journal of the Franklin Institute* **349**(3), 1174–1197.

[7] de Jong P & Heller GZ (2008). *Generalized Linear Models for Insurance Data (International Series on Actuarial Science)*. Cambridge University Press, Cambridge.

[8] Diciccio TJ & Romano JP (1988). A review of bootstrap confidence intervals. *Journal of the Royal Statistical Society Series B: Statistical Methodology* **50**(3), 338–354.

[9] Dubey SD (1970). Compound gamma, beta and F distributions. *Metrika* **16**(1), 27–31.

[10] Efron B (1992). Bootstrap methods: Another look at the jackknife. In *Breakthroughs in Statistics: Methodology and Distribution*, 569–593. Springer, New York.

[11] Feng C, Wang H, Lu N, Chen T, He H, Lu Y & Tu XM (2014). Log-transformation and its implications for data analysis. *Shanghai Archives of Psychiatry* **26**(2), 105–-109. https://doi.org/10.3969/j.issn.1002-0829.2014.02.009

[12] Gagnon P & Wang Y (2024). Robust heavy–tailed versions of generalized linear models with applications in actuarial science. *Computational Statistics & Data Analysis* **194**, 107920.

[13] Geman S and Hwang CR (1982). Nonparametric maximum likelihood estimation by the method of sieves. *The annals of Statistics* **10**(2), 401–414.

[14] Goldburd M, Khare A, Tevet D & Guller D (2025). *Generalized Linear Models*

for Insurance Rating (Casualty Actuarial Society, CAS Monographs Series 5) (2-nd Edition). Casualty Actuarial Society, Virginia.

[15] Hall P (1988). On symmetric bootstrap confidence intervals. *Journal of the Royal Statistical Society Series B: Statistical Methodology* **50**(1), 35–45.

[16] Hayawi H, Ali TH & Omer AW (2025). Gamma regression model for insurance claims analysis: A comparative study on link functions and their influence on cost predictions. Preprints, 202508.0841. v1.

[17] Huber PJ & Ronchetti EM (2009). *Robust Statistics* (2-nd Edition). John Wiley & Sons, New York.

[18] Jeong H & Valdez EA (2020). Predictive compound risk models with dependence. *Insurance: Mathematics and Economics* **94**, 182–195.

[19] Johnson NL, Kotz S & Balakrishnan N (1994). *Continuous Univariate Distributions* (Vol. 1, 2-nd Edition). John Wiley & Sons, New York.

[20] Jorgensen B (2012). *Statistical Properties of the Generalized Inverse Gaussian Distribution*(Vol. 9). Springer Science & Business Media, Berlin.

[21] Kiefer J and Wolfowitz J (1956). Consistency of the maximum likelihood estimator in the presence of infinitely many incidental parameters. *The Annals of Mathematical Statistics* **27**(4), 887–906.

[22] Klugman SA, Panjer HH & Willmot GE (2013). *Loss Models: From Data to Decisions*. John Wiley & Sons, New York.

[23] Laird N (1978). Nonparametric maximum likelihood estimation of a mixing distribution. *Journal of the American Statistical Association* **73**(364), 805–811.

[24] Lawless JF (2011). *Statistical Models and Methods for Lifetime Data* (2-nd Edition). John Wiley & Sons, New York

[25] Lehmann EL & Casella G (1998). *Theory of Point Estimation*. Springe, New York.

[26] Lehmann EL (1999). *Elements of Large Sample Theory*. Springer, New York.

[27] Li X and Tian GL (2022). The upper–crossing/solution (US) algorithm for root–finding with strongly stable convergence. arXiv preprint arXiv:2212.00797

[28] Lindsay BG (1983). The geometry of mixture likelihoods: A general theory. *The Annals of Statistics* **11**(1), 86–94.

[29] Manning WG, Basu A & Mullahy J (2002). *Modeling costs with generalized gamma regression*. The University of Chicago, Chicago.

[30] Mathai AM & Moschopoulos PG (1991). On a multivariate gamma. *Journal of Multivariate Analysis* **39**(1), 135–153.

[31] McCullagh P & Nelder JA (2019). *Generalized Linear Models* (2-nd Edition). Chapman & Hall/CRC, Boca Raton.

[32] McDonald JB (1984). Some generalized functions for the size distribution of income. *Econometrica* **52**(3), 647–665.

[33] Oh DH & Patton AJ (2016). High-dimensional copula-based distributions with mixed frequency data. *Journal of Econometrics* **193**(2), 349–366.

[34] Schwarz G (1978). Estimating the dimension of a model. *The Annals of Statistics* **6**(2), 461–464.

[35] Shen X and Wong WH (1994). Convergence rate of sieve estimates. *The Annals of Statistics* **22**(2), 580–615.

[36] Tian GL and Liu XY (2022). The normalized expectation–maximization (N-EM) algorithm. *Technical Report at Department of Statistics and Data Science, SUSTech*.

[37] Weibull W (1951). A statistical distribution function of wide applicability. *Journal of Applied Mechanics* **18**(3), 293–297.

[38] 钱峰, 刘文娟 (2006). 约束下混合模型的参数估计 [J]. 南通大学学报 (自然科学版) **5**(3): 100–102.

[39] 唐利民 (2008). 一种新的求解非线性最小二乘问题的牛顿迭代算法 [J]. 长沙交通学院学报 **24**(3): 18–23.

[40] 郭照庄, 霍东升, 孙月芳 (2008). 密度核估计中窗宽选择的一种新方法 [J]. 佳木斯大学学报 (自然科学版) **26**(3): 401–403.

2. 项目的研究内容、研究目标，以及拟解决的关键科学问题（此部分为重点阐述内容）；

根据前文背景和研究动态，本项目的研究内容、目标及关键科学问题分为以下三点：

2.1 课题一：基于潜变量表征的复杂异质性数据可解释建模与优化

2.1.1 研究目标与内容

本课题旨在针对生物医学、金融保险及可靠性工程等领域中广泛存在的正向偏态、过度离散（Over-dispersion）且具有显著个体异质性的连续数据，构建一套兼具统计严谨性与概率机器学习表征能力的可解释建模框架。我们想要打破传统伽马回归模型中“均值–方差强耦合”的理论束缚，为复杂异质性数据提供一种计算稳定、解释性强且具备机器学习泛化能力的底层概率表征工具。具体研究内容如下：

(i) **基于潜变量表征的广义混合伽马（Ge-Ga）分布族构建：**突破传统两参数分布的结构限制，通过在 Type I Gamma 分布中创新性地引入正向随机潜变量 τ，以混合表示（Mixture Representation, MR）[38]：

$$\tau \sim f_\tau(\tau|\boldsymbol{\lambda}) \quad \text{和} \quad X|\tau \sim \mathrm{Ga}(\alpha, \mu\tau), \quad \alpha > 0,\ \mu > 0$$

的方法构建 Ge-Ga 分布族。重点研究当 τ 服从广义逆高斯（GIGau）分布族（包括逆伽马、逆高斯及倒数逆高斯分布）时的多种具体概率演化形态，并推导其解析密度函数与统计性质。

(ii) **复杂数据异质性的解析级解耦与量化：** 深入探索 Ge-Ga 框架下的方差分解机制，将观测数据的总变异精确解耦为群体层面的结构性变异与个体层面的随机异质性，即

$$\mathrm{Var}(X) = \frac{\mu^2}{\alpha} + \frac{\mu^2}{\alpha}(\alpha+1)\mathrm{Var}(\tau),$$

通过标准化潜变量期望，实现模型参数的精准识别，从而为 AI 系统中的不确定性量化提供具备明确物理意义的解释路径。

(iii) **针对非闭合积分似然的高效正则化 EM（N-EM）算法：** 针对 Ge-Ga 模型似然函数中因潜变量引入而产生的复杂积分瓶颈，为形如

$$\begin{aligned}\ell(\boldsymbol{\theta}|Y_{\text{obs}}) &= n[\alpha\log\alpha - \log\Gamma(\alpha)] - n\alpha\log\mu + (\alpha-1)\sum_{i=1}^{n}\log x_i \\ &\quad + \sum_{i=1}^{n}\log\left[\int_0^\infty h(\tau|x_i,\boldsymbol{\theta})\,\mathrm{d}\tau\right]\end{aligned}$$

的似然函数就设计并实现正则化期望最大化（N-EM）算法。通过构造正则化密度函数（Normalizing Density Function）：

$$g(\tau|x_i,\boldsymbol{\theta}) \triangleq \frac{h(\tau|x_i,\boldsymbol{\theta})}{\int_0^\infty h(s|x_i,\boldsymbol{\theta})\,\mathrm{d}s}, \quad \tau > 0,$$

与替代函数（Surrogate Function）：

$$\begin{aligned}Q(\boldsymbol{\theta}|\boldsymbol{\theta}^{(t)}) &= c^{(t)} + n[\alpha\log\alpha - \log\Gamma(\alpha)] - n\alpha(\log\mu + \bar{d}^{(t)}) + \alpha\sum_{i=1}^{n}\log x_i \\ &\quad - \frac{\alpha}{\mu}\sum_{i=1}^{n} b_i^{(t)} x_i + \sum_{i=1}^{n}\int_0^\infty \log[f_\tau(\tau|\boldsymbol{\lambda})]\cdot g(\tau|x_i,\boldsymbol{\theta}^{(t)})\,\mathrm{d}\tau,\end{aligned}$$

解决传统优化算法在处理非闭合似然函数时的收敛不稳定问题，并结合具有强稳定收敛性质的 US 算法[27] 进行求解。

(iv) **统计推断理论验证与均值回归框架开发：** 建立极大似然估计（MLE）在 Cramér-Rao 准则[25, 26] 下的渐近一致性与正态性理论：

$$\hat{\boldsymbol{\theta}}_n \to \boldsymbol{\theta}_0 \quad \text{和} \quad \sqrt{n}\left(\hat{\boldsymbol{\theta}}_n - \boldsymbol{\theta}_0\right) \xrightarrow{\mathrm{D}} N\left(\mathbf{0}, \mathbf{J}^{-1}(\boldsymbol{\theta}_0)\right),$$

同时构建 Ge-Ga 均值回归模型，

$$\log E(X_i) = \boldsymbol{z}_{(i)}^\top\boldsymbol{\beta} \quad \text{或者} \quad \mu_i = \frac{\exp(\boldsymbol{z}_{(i)}^\top\boldsymbol{\beta})}{E(\tau)}, \quad i = 1,\ldots,n,$$

利用对数链接函数刻画多维协变量对正向响应变量的非线性影响，并开发基于迭代重权最小二乘（Iterative Reweighted Least Square，IRLS）[39] 的稳健求解程序。

2.1.2 拟解决的关键科学问题

(a) **异质性解耦的数学表征机制：** 如何通过引入特定潜变量分布，在保持模型闭合性的同时，实现对复杂正向数据变异来源的结构化剥离与精准刻画？

(b) **复杂积分似然的稳健优化路径：** 面对无法解析表达的复杂积分对数似然函数，如何构建具备强收敛性保证且无需繁琐超参调优的正则化数值迭代算法，以支撑复杂概率模型的高效工业化部署？

2.2 课题二：面向高维正相关协同演化机制的多元联合概率架构与回归推断

2.2.1 研究目标与内容

本课题旨在解决现实世界（如精准医疗、公共卫生、金融风控等）中广泛存在的多维正向数据（Positive Data）的联合建模难题，特别是针对具有协同演化特性且高度正相关的复杂指标体系，构建灵活的多元概率架构。希望构建一套能够精准刻画多维正向数据“协同演化”规律的概率机器学习架构，解决传统模型在处理正相关高维数据时计算效率低下、相关结构表达力不足的问题，为多维临床指标分析与复杂保险费率精算[7, 14, 18] 提供核心算法支撑。具体研究内容如下：

(i) **基于共享潜变量机制的多元广义混合伽马（Ge-Ga$_d$）分布架构：** 利用混合表示技术，通过引入一个共享的正向潜变量 τ，构建 d 维多元广义混合伽马分布：

$$\{X_j|\tau\}_{j=1}^{d} \overset{\text{ind}}{\sim} \text{Ga}(\alpha, \mu_j\tau), \quad \alpha > 0,\ \mu_j > 0 \quad \text{和} \quad \tau \sim f_\tau(\tau|\boldsymbol{\lambda}),$$

研究在给定 τ 条件下各分量独立服从伽马分布的构造机理，从而在理论上自然诱导出各维度间的正相关性，打破传统多元分布构造（如 Cheriyan 和 Ramabhadran 模型）中相关结构僵化、各维度离散度受限的瓶颈。

(ii) **多维变量协同演化与异构分散性的量化分析：** 推断 Ge-Ga$_d$ 家族各成员（如 IGa-Ga$_d$、LSGIG-Ga$_d$、LN-Ga$_d$）的协方差阵与矩特性。重点分析共享潜变量 τ 如何驱动多维分量（如患者肝功能中 ALT、AST、ALP 等生化指标）的协同演化，并探讨模型如何同时捕捉各维度间特异的异构分散性（Over-dispersion）：

$$\text{Cov}(X_j, X_{j'}) = \mu_j\mu_{j'} \quad \text{和} \quad \text{Var}(\tau)\text{Var}(X_j) = \mu_j^2\left\{\left(1+\frac{1}{\alpha}\right)\text{Var}(\tau) + \frac{1}{\alpha}\right\},$$

以实现对多维数据内部复杂依赖关系的深度解耦。

(iii) **高维多元均值回归框架与联合效应评估：**构建多元 Ge-Ga$_d$ 均值回归模型，建立多维响应变量与协变量阵 $\mathbf{Z}$ 之间的非线性对数链接关系：

$$\log E(X_{ij}) = \log[\mu_{ij} E(\tau)] = \boldsymbol{z}_{(i)}^{\top} \boldsymbol{\beta}_j \quad \text{亦或者}$$

$$\mu_{ij} = \frac{\exp(\boldsymbol{z}_{(i)}^{\top} \boldsymbol{\beta}_j)}{E(\tau)}, \quad i = 1, \ldots, n,\ j = 1, \ldots, d,$$

研究如何通过回归系数 $\{\beta_1, \ldots, \beta_d\}$ 准确量化外部风险因素（如年龄、BMI、生活习惯等）对多项健康指标或支出指标的协同影响，并开发适用于高维参数空间的推断程序。

(iv) **多元 N-EM 算法的优化与高并发场景下的计算实现：**针对多元似然函数中更高复杂度的积分难题，优化 N-EM 算法。通过构建标准归一化密度函数，实现对复杂参数空间的坐标上升式迭代优化

$$\begin{cases} \alpha^{(t+1)} &= \operatorname{sol}\left\{1 - \bar{d}^{(t)} - \dfrac{1}{d}\displaystyle\sum_{j=1}^{d} \log \mu_j + \dfrac{1}{nd}\displaystyle\sum_{i=1}^{n}\sum_{j=1}^{d}\left(\log x_{ij} - \dfrac{b_i^{(t)} x_{ij}}{\mu_j}\right) \right. \\ & \qquad \left. + \ \log \alpha - \psi(\alpha) = 0\right\}, \\ \mu_j^{(t+1)} &= \dfrac{1}{n}\displaystyle\sum_{i=1}^{n} b_i^{(t)} x_{ij}, \quad \text{对 } j = 1, \ldots, d, \\ \lambda_k^{(t+1)} &= \operatorname{sol}\left\{\displaystyle\sum_{i=1}^{n}\int_0^{\infty} \dfrac{\partial \log f_\tau(\tau|\boldsymbol{\lambda})}{\partial \lambda_k} \cdot g(\tau|\boldsymbol{x}_i, \boldsymbol{\theta}^{(t)})\, \mathrm{d}\tau = 0\right\}, \quad \text{对每个 } k, \end{cases}$$

并研究算法在大样本、高维度数据下的数值稳定性与收敛精度。

2.2.2 拟解决的关键科学问题

(a) **多维协同演化的概率表征一致性：**如何通过共享潜变量机制，在保证各边缘分布灵活性（异构离散）的同时，维持多维变量间正相关结构的数学一致性与物理可解释性？

(b) **高维回归推断中的计算复杂度解耦：**在面对包含大量回归系数与复杂积分项的多元联合似然函数时，如何设计高效的迭代优化路径（如优化后的 N-EM 算法），以实现在保证全局收敛性的前提下，显著提升高维参数估计的计算效率？

2.3 课题三：数据驱动的非参数自适应稳健分布理论及其在可信预测中的应用

2.3.1 研究目标与内容

本课题针对生物医学等安全敏感领域中复杂极端数据难以被预设参数分布准确刻画的痛点，摒弃对混合潜变量 τ 的具体分布假设，旨在建立一套基于数据驱动的非参数多元混合伽马（NPMGA）分布理论体系，并探索其在可信 AI 预测中的稳健优化机制。课题目标为构建一套完全由数据驱动的非参数多元混合分布底层架构，彻底摆脱传统参数化模型带来的“模型误设”风险。通过引入 Sieve 正则化与高效 MM 迭代算法，实现对极端复杂、未知异质性结构的正向连续数据的自适应刻画，为大健康、精准医疗等高风险应用场景提供具备强鲁棒性与高可信度的概率预测底座。课题的具体研究内容如下：

(i) **基于直方图离散化的非参数潜变量重构与 NPMGA$_d$ 模型构建：**打破课题一和课题二中潜变量需服从特定参数族（如 GIGau 族或 Lognormal）的预设限制。利用直方图离散化（Histogram-based discretization）技术

$$\Pr(\tau = \tau_j) = p_j, \quad j = 1, \ldots, M \quad \text{或者} \quad F_\tau(\tau|\boldsymbol{p}) = \sum_{j=1}^{M} p_j \cdot I(\tau \geqslant \tau_j),$$

与黎曼–斯蒂尔吉斯积分逼近（Riemann–Stieltjes approximation）方法

$$\sum_{i=1}^{n} p_i g(x_i) \to \int_a^b g(x)\,\mathrm{d}F(x),$$

将连续潜变量的分布近似为有限个离散概率质量（Probability masses）的组合。在此基础上，构建非参数多元混合伽马（NPMGA$_d$）分布模型，使其能够自适应地逼近任意具有正向支持集的复杂潜在异质性结构。

(ii) **融合 Sieve 正则化与 FDR 框架的数据自适应离散度控制：**针对非参数离散化过程中可能引发的维度爆炸与严重过拟合问题，引入 Sieve 正则化思想，设定 $M_t = O(n^\alpha)$，$\alpha \in (0,1)$。通过限制支撑点数量 M 的无序增长来控制模型复杂度。建立基于假发现率（FDR）的数据自适应筛选框架或交叉验证（Cross-validation）机制，动态确定最优的区间划分数 $M_{\mathbf{opt}}$，在模型拟合灵活性与泛化稳定性之间寻求最佳平衡。

(iii) **基于高斯–拉盖尔求积与 MM 算法的稳健计算引擎设计：**为解决非参数模型中支撑点位置及其对应概率权重的联合估计难题，探索利用高斯–拉盖尔求积（Gauss–Laguerre quadrature）的节点，即 n 阶高斯–拉盖尔多项式

$$L_n(x) = \frac{\mathrm{e}^x}{n!}\frac{\mathrm{d}^n(\mathrm{e}^{-x}x^n)}{\mathrm{d}x^n}$$

的零点作为初始支撑点网格，以确保对指数衰减积分区域的有效覆盖与计算稳定性。设计并优化 MM 迭代算法[23]，实现高维权重参数 p 与底层模型

参数的高效、稳定求解：

$$p_j^{(t+1)} = \frac{\sum_{i=1}^n g_{ij}^{(t)}}{\sum_{j=1}^M \sum_{i=1}^n g_{ij}^{(t)}} = \frac{\mathbf{1}_n^\top \boldsymbol{g}_j^{(t)}}{\mathbf{1}_n^\top \mathbf{G}^{(t)} \mathbf{1}_M}, \quad j = 1, \ldots, M,$$

构建适用于大规模数据集的计算引擎。

(iv) **非参数多元回归建模及其在医疗/健康领域的可信部署验证：**在 NPMGA$_d$ 框架下构建更为稳健的均值回归模型，将高维协变量纳入分析体系。利用真实的医学与健康数据（如 NHANES 或高风险医疗支出数据），系统评估 NPMGA$_d$ 模型在分布外（OOD）样本上的泛化能力与预测鲁棒性，验证该数据驱动范式在赋能可控、可信 AI 决策系统中的应用价值。

2.3.2 拟解决的关键科学问题

(a) **非参数离散逼近的最佳平衡性边界：**在缺失潜变量真实分布先验信息的前提下，如何构建数据自适应的惩罚与筛选准则（如结合 Sieve 理论与交叉验证），以精准界定离散逼近精度与模型过拟合风险之间的理论边界？

(b) **高维参数空间的稳定寻优与可信推断：**面对包含海量未知权重参数与复杂支撑点结构的非参数对数似然函数，如何设计结构稳定（如利用高斯–拉盖尔节点初始化）且能保证全局次优收敛的高效数值迭代算法（MM 算法），进而为模型的高可信度输出提供算法保障？

3. 拟采取的研究方案及可行性分析（包括研究方法、技术路线、实验手段、关键技术等说明）；

基于前文确立的研究目标与关键科学问题，本项目将按课题递进开展，采取严密的数理推导与前沿数据科学算法相结合的研究路径。拟采取的研究方案及可行性分析如下：

3.1 课题一的研究方案及可行性分析

研究方案：

根据前文的理论架构分析，关于课题一，我们计划采取的研究方案如下：

(i) **在理论建模方面，构建广义混合伽马（Ge-Ga）概率演化体系。**我们将 Type I 伽马分布作为基线分布，创新性地引入服从广义逆高斯（GIGau）族（涵盖逆伽马、逆高斯及倒数逆高斯分布等）的随机潜变量 τ。在此基础上，通过严密的概率测度变换与积分推导，得出各类 Ge-Ga 分布的精确解析密度函数。进一步，利用全方差公式（Law of Total Variance），对数据的变异性进行结构化解耦，解析量化过度离散（Over-dispersion）效应。

(ii) **在算法设计方面，开发突破复杂积分瓶颈的 N-EM 算法**。针对潜变量引入导致对数似然函数中包含复杂非闭合积分的问题，我们摒弃传统的直接数值求导（如 Newton-Raphson 法），转而构建正则化密度函数，利用隐变量的后验期望推导出目标函数的全局下界（Surrogate Function）。通过正则化期望最大化（N-EM）迭代框架，将复杂的含积分优化问题转化为易于求解的子参数更新过程，并结合 US 算法实现形状参数的高效优化。

可行性分析：

本课题旨在解决非闭合似然函数在复杂分布中的求解难题，其可行性主要建立在以下三个坚实的支撑点上：

(i) **理论推导的严密性与闭环：**本课题并未采用容易陷入局部最优或依赖海森矩阵（Hessian Matrix）求逆的传统牛顿–拉夫逊（Newton–Raphson）类算法，而是独创性地构建了正则化密度函数。通过引入潜变量的后验期望，我们能够严格推导出目标对数似然函数的全局替代下界，从而在理论层面化解了含积分对数似然函数的优化难题。

(ii) **N-EM 算法与 US 算法的数值稳定性：**我们所采用的 N-EM 算法在数学上被严格证明具有单调递增属性（Monotonicity Property），从根本上保证了整体算法的全局收敛性。更为关键的是，针对形状参数的非线性求根问题，我们将无缝衔接具有强稳定收敛特性的 US 算法。初步的数值模拟已充分验证，该套组合算法对初始值极度不敏感，彻底扫除了模型在工业界或复杂医疗数据落地时的计算发散风险。

(iii) **扎实的前期工作支撑：**申请人团队目前已完成了单变量 Ge-Ga 分布核心理论框架的初步搭建，成功推导了其复杂的解析密度函数与方差分解公式，并完成了最大似然估计（MLE）的渐近一致性与正态性证明。这些高完成度的前期成果，为本课题的顺利结题提供了绝对的保障。

3.2 课题二的研究方案及可行性分析

研究方案：

针对多维复杂数据间的协同演化与强耦合特性，关于课题二，我们计划采取的研究方案如下：

(i) **在多元联合架构构建方面，设计“共享潜变量”驱动的多元混合表示（MR）**。我们将引入一个全局共享的正向潜变量 τ，在给定 τ 的条件下，设定各维度的响应变量条件独立且服从异构的伽马分布。我们将通过多元矩母函数与联合特征函数的推导，证明该机制不仅能灵活刻画边缘分布的重尾特性，更能从底层数学上自然诱导出各维度间的一致正相关性（Positive Correlation）。

(ii) **在高维均值回归与推断方面，建立多元联合特征映射网络**。针对多项医学/经济指标受同一组复杂协变量（如患者年龄、BMI 等）影响的场景，我们将构建多元 Ge-Ga 均值回归模型。利用对数链接函数将协变量矩阵与多元响应的联合均值空间对齐，推导基于费雪信息矩阵（Fisher Information Matrix）和迭代重权最小二乘法的高维参数估计策略，并扩展我们的算法至多元高并发场景。

可行性分析：

针对高维正向数据建模中常见的“维度灾难”与“相关结构僵化”瓶颈，本课题的可行性不仅体现在架构的巧妙性上，更体现在极高的计算扩展能力上。

(i) **“降维解耦”的创新数学构造：**传统的多元统计模型（如 Copula 结构或 Cheriyan-Ramabhadran 加法构造）在处理高维数据时，联合密度计算复杂度往往呈指数级爆炸。本课题采用极其简洁优雅的“共享潜变量”乘法机制，在给定单一潜变量 τ 的条件下，各维度的响应变量实现条件独立。这不仅自然诱导了变量间的一致正相关性，还在底层逻辑上避开了高维协方差矩阵的繁琐设定。

(ii) **将高维积分坍缩为一维积分的计算可行性：**得益于上述条件独立的构造机制，多元 Ge-Ga 模型在推断多维联合似然函数时，无论数据的维度 d 如何成倍增长，其核心的复杂积分项始终能够坍缩（Collapse）为对单一潜变量 τ 的一维数值积分。这一极具巧思的降维特性，使得将一维 N-EM 算法扩展至高维并发场景不仅在理论上完全畅通，在实际算力消耗上也极其经济。

(iii) **回归框架扩展的平滑性：**申请人已在理论上理清了多维响应变量与高维协变量阵之间的对数链接映射关系，基于费雪信息矩阵的迭代重权最小二乘法在高维广义线性模型中已有成熟的借鉴范式，能够确保多元平均回归推断的顺利实施。

3.3 课题三的研究方案及可行性分析

研究方案：

为彻底消除由于潜变量参数化先验假设带来的模型误设（Mis-specification）风险，关于课题三，我们计划采取的研究方案如下：

(i) **在数据自适应重构方面，采用基于直方图与高斯–拉盖尔求积的非参数离散化逼近**。摒弃 τ 服从特定参数族的前提，我们将利用黎曼–斯蒂尔吉斯积分（Riemann–Stieltjes）将连续混合分布转化为离散混合体。为确保计算精度与覆盖度，我们创新性地引入高斯–拉盖尔求积（Gauss–Laguerre quadrature）的节点（Nodes）作为初始潜变量的支撑点网格，以此自适应地捕捉任何极端未知的异质性数据结构。

(ii) **在稳健优化机制设计方面，结合 Sieve 正则化与 MM 算法**。为了抑制支撑点增多带来的过拟合问题，我们将引入 Sieve 理论对非参数维度的无序扩张进行惩罚，或结合假发现率（FDR）进行最优节点数的动态筛选。在参数求解上，采用 MM 框架，通过构造凸优化的替代函数（Surrogate），实现对高维概率权重向量与底层模型参数的联合、稳健迭代求解。

(iii) **在泛化能力验证方面，开展分布外（OOD）实证与可信 AI 部署**。在完成核心代码封装后，将其应用于高度异质性的真实数据集（如 NHANES 或高风险医疗支出数据）。重点测试模型在不同子群体间（如健康群体与重疾群体）的分布外预测鲁棒性，论证其在医疗问答、风控决策等安全敏感型 AI 系统中的底座价值。

可行性分析：

非参数分布估计在机器学习界历来被公认为极具挑战，极易陷入过拟合与高维寻优陷阱。本课题迎难而上，其可行性依托于以下顶层数值分析与优化算法的联合：

(i) **高斯–拉盖尔求积定理的理论最优性：**由于我们处理的是正向连续数据的潜变量（定义域为 $[0,\infty)$），本课题并没有盲目选择离散化网格，而是创新性地引入了数值分析领域的高斯–拉盖尔（Gauss–Laguerre）求积节点。该定理从数学严密性上保证了在正半轴无界区间内，以指数衰减为权重的积分逼近具有代数精度的最优性，这为我们捕获极端未知异质性提供了无可挑剔的网格底座。

(ii) **MM 算法对非凸参数空间的高效降维：**针对非参数模型面临的海量权重参数联合估计难题，我们将引入 MM 迭代优化框架。利用 Jensen 不等式，MM 算法能够将复杂的“对数–求和”目标函数转化为极易求解的“求和–对数”替代函数，其强大的分块单调上升特性，有效避免了高维概率单纯形空间中的局部最优陷阱，确保了权重参数分布的稳定逼近。

(iii) **前期工作架构的成功迁移：**申请人团队已在同等难度的“非参数多元混合正态（NPMN）”分布研究中取得了较大进展，成功运用直方图离散化与 Sieve 理论解决了过拟合问题。NPMN 框架下的底层逻辑（如参数估计的收敛性与渐近 Oracle 性质）能够安全成功地迁移至本课题的 NPMGA 模型中。

4. 本项目的特色与创新之处；

本项目紧扣当前数据科学与人工智能领域在处理复杂、异质、多维正向数据时的底层理论痛点，在概率表征机制、联合分布架构与稳健优化算法三个维度实现了系统性突破。具体而言，本项目的特色与创新之处体现在以下三个方面：

4.1 课题一的特色与创新之处

本课题开创性地提出了基于潜变量表征的 Ge-Ga 分布族及 N-EM 优化算法，突破了复杂异质性数据可解释建模的理论瓶颈。

(i) **理论破局：**首次系统性地将广义逆高斯（GIGau）分布族作为混合潜变量引入 Type I 伽马分布，彻底打破了传统经典分布（如 Gamma、Inverse Gaussian）中“均值与方差强耦合”的刚性理论束缚。该架构不仅保留了传统统计模型的高度可解释性，更实现了对数据总变异的“解析级”解耦（分解为群体结构性变异与个体随机异质性），为 AI 模型在医疗、风控等高风险场景中的不确定性量化提供了全新的数理底座。

(ii) **算法创新：**针对引入潜变量后引发的复杂非闭合积分似然优化灾难，独创性地设计了正则化 EM（N-EM）算法。通过构造正则化密度函数（ndf）与替代函数（Surrogate），实现了复杂参数空间下的无梯度、稳定单调寻优，填补了复杂混合分布高效数值求解的算法空白。

4.2 课题二的特色与创新之处

本课题独创“共享潜变量”的多维协同机制，重构了高维正相关数据的多元联合概率架构。

(i) **架构革新：**面对多模态健康指标等高维数据，摒弃了传统 Copula 函数在超高维下遭遇的“计算维度灾难”与先验主观随意性，也突破了传统加法构造（如 Cheriyan–Ramabhadran 模型）导致的多维同质化局限。本项目创新性地提出通过“共享正向潜变量 τ”的乘法混合构造机制，在底层数学逻辑上自然诱导并精准刻画了多维变量间的正相关协同演化效应。

(ii) **维度解耦：**该多元机制极具巧思，它允许高维数据在保持全局正相关的同时，各边缘分量仍能拥有完全独立的异构离散度（Over-dispersion）。这使得多元 Ge-Ga 回归模型在应对复杂的高维协变量联合推断时，展现出了极其卓越的表达灵活性与计算降维优势。

4.3 课题三的特色与创新之处

本课题构建了完全数据驱动的非参数自适应分布理论，为 AI 系统的稳健预测提供了 OOD 泛化范式。

(i) **范式转移：**彻底摒弃了传统概率模型对潜变量必须服从特定参数族的先验假设，首次将直方图离散化、黎曼–斯蒂尔吉斯积分逼近与 Sieve 正则化理论深度融合。这使得模型能够完全依靠数据驱动，自适应地逼近并拟合现实世界中极端、未知的复杂异质性结构，从根本上消除了“模型误设（Mis-specification）”风险。

(ii) **稳健计算：**巧妙引入数值分析中的高斯–拉盖尔（Gauss–Laguerre）求积节点作为底层支撑点网格，并结合 MM 迭代优化框架，完美化解了非参数离散化带来的高维过拟合与初值敏感的陷阱。这一非参数稳健优化范式，极大地提升了模型在分布外（OOD）数据上的泛化能力，为深圳市大健康与类脑智能等前沿产业部署“可控、可信 AI 系统”提供了极具前瞻性的算法保障。

5. 年度研究计划及预期研究结果（包括拟组织的重要学术交流活动、国际合作与交流计划等）。

5.1 年度研究计划

本项目的研究期限为三年, 其预期进展大体规划如下：

(1) 第一年上半年，启动课题的研究，完成相关文献资料的初期整理和研读工作，分析明确课题中的关键环节。第一年下半年重点研究课题一，构建其模型与算法，完成相关模拟和实际数据的分析，以及理论的推导。并且完成第一篇文章的投稿工作。在学术交流方面本年度主要计划和国内同行专家以开会交流为主，和国际专家以访问形式为主。同时尽可能参加国内外相关主题的学术会议。

(2) 第二年上半年，重点研究课题二的相关问题，例如算法收敛性的推导。第二年下半年完成课题二的剩余研究和第二篇文章的投稿，同时积极进行课题三的研究，比如数值模拟。本年度计划邀请国内外同行专家以学术访问的形式进行更密集的学习交流，同时计划举办一场与项目研究课题密切相关的复杂数据分析研讨会。计划邀请访问和参加会议的国外专家包括来自美国、加拿大等地的多名专家。

(3) 第三年上半年，重点研究课题三的理论构建。第三年下半年，重点在第三个课题的剩余研究，比如展示在多个领域里的应用，同时整理总结研究成果，完成第三篇文章的投稿。这一阶段预计为整个项目的收尾阶段，争取所有文章都能发表于统计学领域的知名期刊。

5.2 预期研究结果

在项目执行的三年内：（1）我们将积极开展与国内外同行（例如 UCLA 生物统计系的 Hua ZHOU 教授、李勋健博士后；UCLA 计算医学和统计系的 LANGE 教授、美国科学院院士；加拿大 Calgary 大学数学与统计学系的 Xuewen LU 教授；清华大学统数系的邓柯教授）的合作交流项目，如参加国内国际学术会议，

邀请国内外同行进行线上报告或来我校进行线下学术交流等。（2）如条件允许，争取每年组织一次小范围的学术交流研讨会。（3）如有可能，还将选派项目组中成员前往国内或境外其他研究机构进行短期的学术交流或访问，以及时掌握该领域的最新发展动态；（4）以该项目为牵引，拟培养 1-2 位博士生。我们最终的研究成果将以 SCI 学术论文、博士论文的形式呈现，初步计划撰写和发表 3 篇 SCI 论文。提交三份年度进展报告，一份项目结题报告。

（二）研究基础与工作条件

1. 研究基础（与本项目相关的研究工作积累和已取得的研究工作成绩）；

项目申请人田国梁教授自 1998.9.1 在北京大学概率统计系从事博士后研究两年、从 2020.5.1 在美国田纳西州 St. Jude 儿童研究医院工作两年、美国马里兰大学工作六年、香港大学工作八年、从 2016.6.30 起全职加入南方科技大学数学系和统计与数据科学系，至今已工作接近十年。在共 28 年的工作期间，一直从事计算统计、生物统计及统计分布理论的研究。讲授本科生课程《数理统计》共 18 年，讲授研究生与本科生共上的课程《计算统计》共 18 年。从 2026.1.1 开始，田国梁教授和其研究团队着手本课题项目的预研工作，每周周六或周日下午 2:00–5:00 共三个小时进行讨论班，查阅了很多文献，进行了诸多数值实验的设计与比较，已取得了初步的模拟阶段性成果。其余预研成果还不深入、不完善、不系统，需要 3 年左右的时间进行持续攻关。与本项目紧密相关的研究方向主要有三个: EM 算法、MM 算法、N-EM 算法、US 算法；复杂统计模型；统计分布理论与统计推断方法。相应的研究工作积累如下，其中标注 “*” 的作者为通讯作者。

项目申请人田国梁教授与本项目相关的研究工作积累：

1、近三年内发表的 4 篇 SCI 文章 (关于统计计算)：

1) Li XJ, **Tian GL**, Zhou H, Lange K (2026). Generalizations of the quadratic bound optimization principle. *Proceedings of the National Academy of Sciences (PNAS) USA* **123**(4), e2525320123. https://doi.org/10.1073/pnas.2525320123

2) Li XJ, Liang J, **Tian GL***, Tang ML and Shi JH (2025). Mean regression model for Type I generalized logistic distribution with a QLB algorithm. *Statistical Papers* **66**, Article Number 118.

3) **Tian GL**, Zhou H, Lange K and Li XJ* (2025). The second-derivative lower-bound function (SeLF) algorithm and three acceleration techniques for maximization with strongly stable convergence. *Statistics and Computing* **35**, Article Number 113.

4) Li XJ, Li S and **Tian GL*** (2024). A new MM algorithm for root–finding problems. *Statistica Neerlandica* **78**(4), 692–701.

2、在香港大学工作期间内出版的英文专著 3 本 (关于统计分布和 EM 算法)：

5) **Tian GL** and Tang ML (2014). *Incomplete Categorical Data Design: Non-randomized Response Techniques for Sensitive Questions in Surveys*. Chapman & Hall/CRC (Statistics in the Social and Behavioral Sciences), Boca Raton, USA.
6) Ng KW, **Tian GL** and Tang ML (2011). *Dirichlet and Related Distributions: Theory, Methods and Applications*. John Wiley & Sons (Wiley Series in Probability and Statistics), New York, USA.
7) Tan M, **Tian GL** and Ng KW (2010). *Bayesian Missing Data Problems: EM, Data Augmentation and Non-iterative Computation*. Chapman & Hall/CRC (Biostatistics Series), Boca Raton, USA.

3、近六年内发表的 5 篇 SCI 文章 (关于统计分布和统计推断)：

8) Liu XY, **Tian GL**(并列一作)，Yuen KC, Zhu LT, Sun Y and Zhang C* (2026). A unified framework for estimation of truncated bivariate normal distribution with non-regular domains: Applications in medicometrics. *Communication in Statistics—Simulation and Computation*, in press.
9) Liu XY, Zhang C*, Yuen KC and **Tian GL** (2025). Squared normal model and its generalization for the analysis of skewed positive data. *Communication in Statistics: Simulation and Computation* **54**(6), 1766–1786.
10) Liu Y, **Tian GL**, Zhang C* and Qin H (2024). A general inferential framework for singly truncated bivariate normal models with applications in economics. *Computational Economics* **64**, 2747–2781.
11) Liu XY, **Tian GL**, Fei Y*, Shu LJ and Zhao Q (2020). Folded normal regression models with applications in biomedicine. *Journal of Computational and Applied Mathematics* **379**, 112941.
12) Zhang C, Tang ML, Li T, Sun Y and **Tian GL*** (2020). A new multivariate Laplace distribution based on the mixture of normal distributions (in Chinese). *Scientia Sinica (Mathematica)* **50**(5): 711–728.

4、近六年内发表的 10 篇 SCI 文章 (关于 EM 算法)：

13) Liu PY, **Tian GL**(并列一作), Yuen KC, Sun Y and Zhang C* (2024). Compositional inverse Gaussian models with applications in compositional data analysis with possible zero observations. *Journal of Statistical Computation and Simulation* **94**(2), 248–278.
14) Wu Q, **Tian GL**(并列一作), Li T, Tang ML and Zhang C (2023). The multivariate component zero-inflated Poisson model for correlated count data analysis. *Australian & New Zealand Journal of Statistics* **65**(3), 234–261.
15) Sun Y*, Zhao SS, **Tian GL**, Tang ML and Li T (2023). Likelihood-based methods for the zero-one-two inflated Poisson model with applications to biomedicine. *Journal of Statistical Computation and Simulation* **93**(6), 956–982.

16) Li XJ, Sun Y, **Tian GL***, Liang JJ and Shi JH (2023). Mean regression model for the zero-truncated Poisson distribution and its generalization. *Computational Statistics and Data Analysis* **179**, Article107650.

17) Deng DL*, Sun YG and **Tian GL** (2022). A multivariate zero-inflated binomial model for the analysis of correlated proportional data. *Journal of Applied Statistics* **49**(11), 2740–2766.

18) Sun Y, **Tian GL**(并列一作), Guo SX, Shu LJ and Zhang C* (2022). Bivariate continuous negatively correlated proportional models with applications in schizophrenia research. *Mathematics* **10**, 353.

19) Tang ML, Wu Q, Yang S and **Tian GL** (2022). Dirichlet composition distribution for compositional data with zero components: An application to fluorescence in situ hybridization (FISH) detection of chromosome. *Biometrical Journal* **64**(4): 714–732.

20) Liu PY, **Tian GL***, Yuen KC, Zhang C and Tang ML (2021). Proportional inverse Gaussian distribution: A new tool for analyzing continuous proportional data. *Australian & New Zealand Journal of Statistics* **63**(4): 579–605.

21) Lin YQ, Zhang YS, **Tian GL*** and Ma CX (2021). Fast QLB algorithm and hypothesis tests in logistic model for ophthalmologic bilateral correlated data. *Journal of Biopharmaceutical Statistics* **31**(1): 91–107.

22) Liu PY, Yuen KC, Wu LC, **Tian GL** and LI T* (2020). Zero-one-inflated simplex regression models for the analysis of continuous proportion data. *Statistics and Its Interface* **13**(2): 193–208.

5、近六年内发表的 5 篇 SCI 文章 (关于 MM 算法)：

23) Li XJ, Li S, **Tian GL***, Shi JH (2024). Modeling paired binary data by a new bivariate Bernoulli model with flexible beta kernel correlation. *Test* **33**, 1180–1224.

24) Li XJ, **Tian GL**(并列一作), Zhang MQ, Ho GTS and Li S* (2023). Modeling under-dispersed count data by the generalized Poisson distribution via two new MM algorithms. *Mathematics* **11**, Article1478.

25) Huang XF*, Liang JJ and **Tian GL** (2023). Valid statistical inference methods for incomplete contingency table with three-category missing data. *Communication in Statistics: Simulation and Computation* **52**(11), 5195–5212.

26) Zhang C, **Tian GL***, Yuen KC, Liu PY and Tang ML (2022). A new multivariate t distribution with variant tail weights and its application in robust regression analysis. *Journal of Applied Statistics* **49**(10): 2629–2656.

27) Zhang C, **Tian GL**(并列一作), Zhai YB and Fei Y* (2022). Valid properties of truncated Student-t regression model with application in analysis of censored data. *Brazilian Journal of Probability and Statistics* **36**(1): 157–184.

2. 工作条件（包括已具备的实验条件，尚缺少的实验条件和拟解决的途径，包括利用国家实验室、国家重点实验室和部门重点实验室等研究基地的计划与落实情况）；

南科大拥有统计研究方面的部分书籍，也购买了相关杂志数据库的电子版权（例如 JSTOR，Springer，Weily，Elsevier 等）。其次，我们也可以通过阅读文献、浏览相关网站、数据库等方式收集一些和本课题相关的研究数据。此外申请人所在系与香港澳门地区知名高校、美国知名高校有着密切交流合作，这为申请人科研工作的顺利进行提供强有力的保障 (例如, 我们可利用香港大学图书馆和 UCLA 图书馆)。在南科大统计与数据科学系, 每个教授都有自己的办公室以及先进的计算机设备。南科大统计与数据科学系为每个在读博士生、在读硕士生和访学者提供一个办公桌并配备计算机。南科大还配备有先进的高性能计算机机群，为项目的实施提供比较充分的硬件条件。

3. **正在承担的与本项目相关的科研项目情况**（申请人和项目组主要参与者正在承担的与本项目相关的科研项目情况，包括国家自然科学基金的项目和国家其他科技计划项目，要注明项目的名称和编号、经费来源、起止年月、与本项目的关系及负责的内容等）；

暂无。

4. **完成国家自然科学基金项目情况**（对申请人负责的前一个已结题科学基金项目（项目名称及批准号）完成情况、后续研究进展及与本申请项目的关系加以详细说明。另附该已结题项目研究工作总结摘要（限 500 字）和相关成果的详细目录）。

项目申请人田国梁负责的前一个已资助期满的科学基金项目

项目申请人田国梁自 2016.6.30 起全职加入南科大后，作为 PI，至今已申请到国自然基金面上项目 2 项，其中第一个面上项目（No.11771199）已于 2021.12.31 结题，第二个面上项目（No.12171225）已于 2025.12.31 结题，详细情况如下:

资助机构: 国家自然科学基金委员会

项目类别: 面上项目

批 准 号: No.12171225

项目名称: 连续比例数据和成分数据分析中若干新的多元模型及新的统计方法

资助金额: 51 万元人民币

起止年月: 2022.01.01–2025.12.31

完成情况: **已经在 2025.12.31 按时结题**

后续研究进展: 暂无后续研究

与本项目的关系: 该项目 (12171225) 包括如下五个方面的研究: **{项目 I}** 首次提出正则化 (Normalized) EM 算法, 简称为 N-EM 算法; **{项目 II}** 首次提出多元比例逆高斯模型, 即多元 PIG 分布和均值回归模型及相应的统计推断方法; **{项目 III}** 首次提出多元比例伽玛模型, 即多元 PGA 分布和均值回归模型及相应的统计推断方法; **{项目 IV}** 首次提出成分逆高斯模型, 即 CIG 分布和均值回归模型及相应的统计推断方法; **{项目 V}** 首次提出带零成分的成分逆高斯模型, 即 ZCIG 分布和均值回归模型及相应的统计推断方法。

而本项目的主要目标是: **课题一** 创建基于潜变量表征的复杂异质性数据可解释建模与 N-EM 优化; **课题二** 构建面向高维正相关协同演化机制的多元联合概率架构与回归推断; **课题三** 聚焦于数据驱动的非参数自适应稳健分布理论及其在可信预测中的应用; 因此前后两个项目在内容上无重叠之处。

该项目 (12171225) 研究工作总结摘要和相关成果详细目录: 详见**附件 6** 和 **附件 7**, 其中附件 6 的文件名为: 2025 年度国自然面上项目 (12171225) 结题报告–田国梁–南科大统数系。附件 7 的文件名为: 2025 年度国自然面上项目 (12171225) 相关成果详细目录–田国梁–南科大统数系。

（三）其他需要说明的问题

1. 申请人同年申请不同类型的国家自然科学基金项目情况（列明同年申请的其他项目的项目类型、项目名称信息，并说明与本项目之间的区别与联系）。

暂无。

2. 具有高级专业技术职务（职称）的申请人或者主要参与者是否存在同年申请或者参与申请国家自然科学基金项目的单位不一致的情况；如存在上述情况，列明所涉及人员的姓名，申请或参与申请的其他项目的项目类型、项目名称、单位名称、上述人员在该项目中是申请人还是参与者，并说明单位不一致原因。

暂无。

3. 具有高级专业技术职务（职称）的申请人或者主要参与者是否具有高级专业技术职务（职称）的申请人或者主要参与者是否存在与正在

承担的国家自然科学基金项目的单位不一致的情况；如存在上述情况，列明所涉及人员的姓名，正在承担项目的批准号、项目类型、项目名称、单位名称、起止年月，并说明单位不一致原因。

暂无。

4. 其他。

暂无。